

UNIDAD 3. CARACTERIZACIÓN DE ÁREAS DE INTERÉS EN IMÁGENES MÉDICAS

1. Reconocimiento de patrones

Patrón

- Arreglo de descriptores
- Característica y descriptor
- Clase de patrones
 - ▣ Familia
 - Propiedades
 - ▣ $\omega_1, \omega_2, \dots, \omega_W$

Descriptor

- ¿Qué califica como un buen descriptor?
- ¿Qué califica la similitud?
- Propiedades por contornos vs por regiones

Descriptores simples

- Área
- Perímetro
- Compacidad o circularidad
$$\frac{(Perímetro)^2}{Área}$$

Descriptores simples

- Excentricidad
- Elongación
- Rectangularidad
- Orientación

Descriptores estadísticos

□ Momentos

▣ Media

$$\mu = \frac{\sum_{x=1}^N x f(x)}{\sum_{x=1}^N f(x)}$$

▣ Varianza

$$\mu_2 = \sigma^2 = \frac{\sum_{x=1}^N (x - \mu)^2 f(x)}{\sum_{x=1}^N x f(x)}$$

Descriptores estadísticos

□ Momentos

▣ Sesgo

$$\mu_3 = \frac{\sum_{x=1}^N (x - \mu)^3 f(x)}{\sum_{x=1}^N x f(x)}$$

▣ Kurtosis μ_4

Momentos de 2D



Momentos de 2D



Respuesta a transformaciones

- Traslación
- Rotación
- Escalamiento

Perfiles

- Firma basada en regiones
- Perfil o proyección
 - ▣ Vertical
 - ▣ Horizontal
 - ▣ Diagonal
- Reconocimiento de caracteres

Momentos de perfil

- P_v , perfil vertical de $f(x, y)$
- P_h , perfil horizontal de $f(x, y)$
- P_d , perfil a 45° de $f(x, y)$
- P_e , perfil a -45° de $f(x, y)$

Descriptores de forma

❏ Centroide

$M = [m_1, m_2, \dots, m_k]$ Matriz de prototipos de los grupos

$m_i = \frac{1}{N_i} \sum_{j=1}^N \gamma_{ij} \mathbf{x}_j$ Medida del i-ésimo grupo con N_i objetos

$\gamma_{ij} = \begin{cases} 1, & \text{si } x_j \in \text{grupo } i \\ 0, & \text{otro caso} \end{cases}$ Matriz de participación con
 $\sum_{i=1}^K \gamma_{ij} = 1 \quad \forall j$

Descriptores de forma

- Orientación
- Ajuste de elipses
 - ▣ Brillo
 - ▣ Elipticidad
 - ▣ Ángulo de posición en función del radio

Reconocimiento de patrones

- Técnicas para asignar patrones a sus respectivas clases
- Arreglos de patrones comunes
 - ▣ Vectores
 - ▣ Cadenas
 - ▣ Árboles



Patrón de comportamiento

Vectores

- Representados $\mathbf{x}, \mathbf{y}, \mathbf{z}$
- Columnas (matrices $n \times 1$)

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

- ▣ Donde cada componente, x_i , representa el i -ésimo descriptor y n es el número total de descriptores asociados al patrón

Vectores

- Otra forma:

$$\mathbf{x} = (x_1, x_2, \dots, x_n)^T$$

- Componentes de un vector dependen del enfoque para describir al patrón físico

Aplicación y enfoques

- Reconocimiento de regiones individuales de la imagen
- Enfoques:
 - ▣ Clasificación estadística
 - ▣ Clasificación sintáctica

Enfoques

- Clasificación estadística
 - ▣ Longitud, área y textura
- Clasificación sintáctica
 - ▣ Descriptores relacionales

Clasificación

- Supervisada
 - ▣ Conjunto de aprendizaje
 - ▣ Entrenamiento
- No supervisada
 - ▣ ~~Conjunto de aprendizaje~~
 - ▣ Cálculos
- Aprendizaje de patrones muestra

Reconocimiento de objetos

- Problema de etiquetado
 - ▣ Modelos de objetos conocidos
- Imagen con uno o más objetos de interés y fondo
- Conjunto de etiquetas
- Asignación de etiquetas correctas

Vectores: Ejemplo

- ❏ Fisher (1936) reportó el uso de lo que entonces era una nueva técnica llamada *análisis discriminante* para reconocer tres tipos de flores iris (*Iris setosa*, *virginica*, *versicolor*) midiendo los anchos y largos de sus pétalos
- ❏ Cada flor es descrita por dos mediciones, lo que lleva a un vector de patrón:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

Iris Virginica



Iris Setosa



Iris Versicolor




Vectores: Ejemplo

- x_1 = longitud del pétalo
- x_2 = ancho del pétalo
- ω_1 = variedad *setosa*
- ω_2 = variedad *virginica*
- ω_3 = variedad *versicolor*

Vectores: Ejemplo

- Tres tipos de flores iris descritas por dos medidas

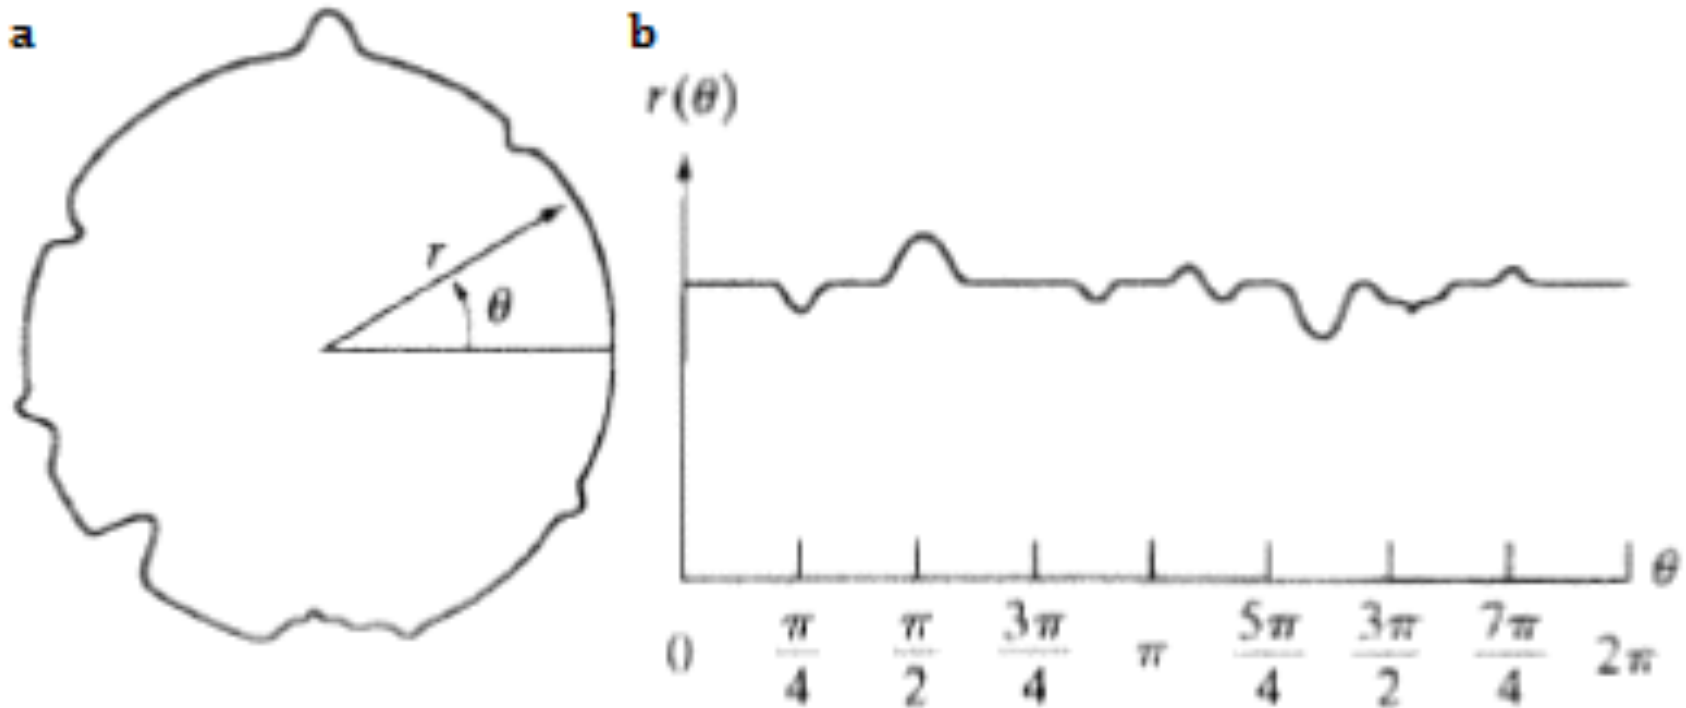


Vectores: Ejemplo

- De un conjunto de mediciones (2) los componentes de un vector de patrones se convierten en la descripción completa de cada muestra física
- Cada flor se vuelve un punto en el espacio Euclidiano en 2-D
- Las mediciones de largo y ancho de pétalo separas adecuadamente la clase *Iris setosa* de las otras dos
- No separan los tipos *virginica* y *versicolor* uno del otro
- Problema clásico de *selección de características*
 - ▣ Grado de separabilidad depende de los descriptores seleccionados

Vectores: Ejemplo 2

- Un objeto ruidoso y su firma correspondiente:



Vectores: Ejemplo 2

- La muestra otro ejemplo de generación de un vector de patrones
- Tipos de figuras ruidosas
- Se elige representar cada objeto por medio de su firma se obtendrían señales 1-D por sus valores de amplitud muestreados
- Se muestrean las firmas a intervalos específicos de θ :
 $\theta_1, \theta_2, \dots, \theta_n$

Vectores: Ejemplo 2



- ❑ Vectores de patrón: $x_1 = r(\theta_1), x_2 = r(\theta_2), \dots, x_n = r(\theta_n)$
 - ▣ Puntos en un espacio Euclidiano de dimensión n
 - ▣ Las clases de patrones pueden imaginarse como “nubes” en n dimensiones
- ❑ Calcular los primeros n momentos estadísticos de una firma
 - ▣ No usar las amplitudes de las firmas
 - ▣ Utilizar estos descriptores como componentes de cada vector de patrón



Patrones y clases

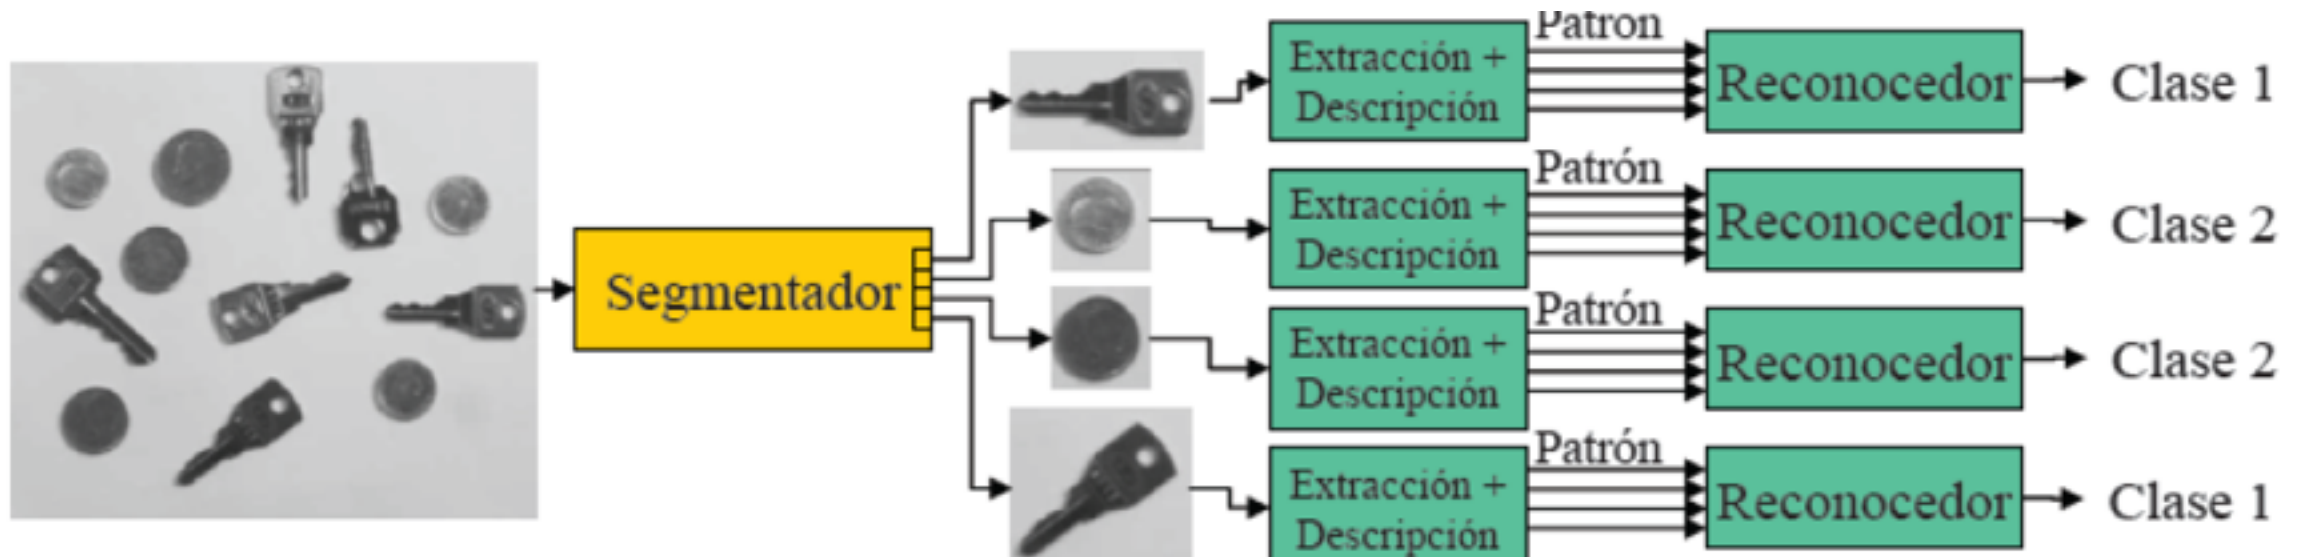
Patrones estructurales

- Codifican relaciones entre componentes del objeto o descriptores



Patrones y clases

- Objetos de misma clase: características similares
- Objetos de diferentes clases: características diferenciadas

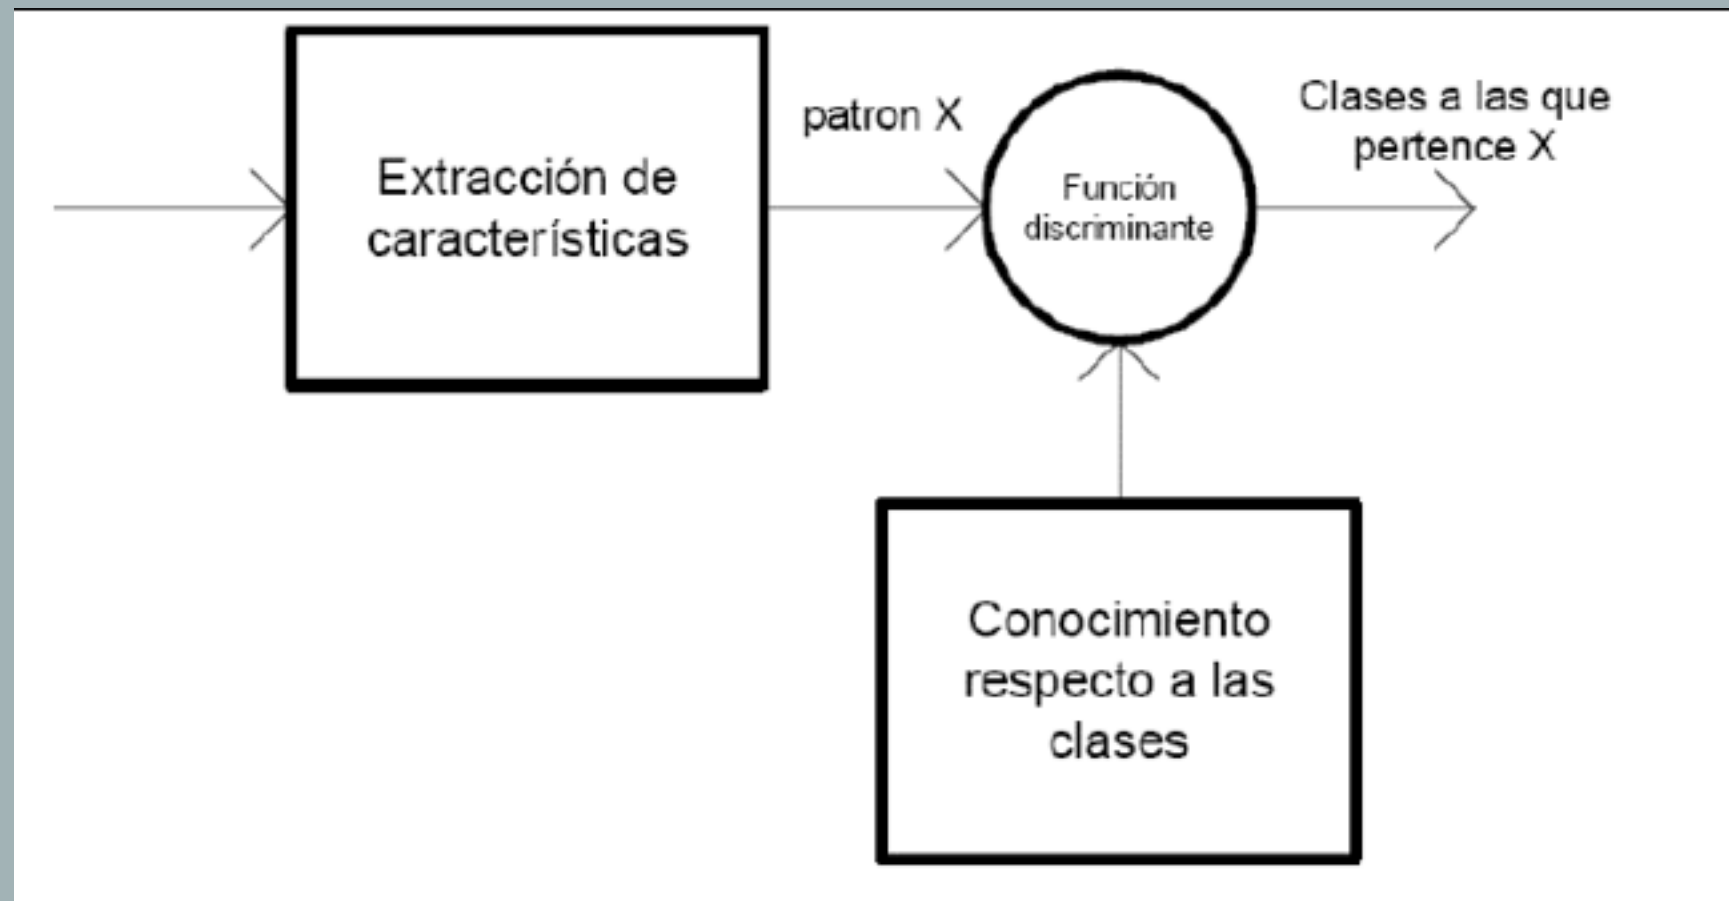


Características discriminantes

- Convertir objeto en vector
 - ▣ **Características discriminantes**
- Determinar las características es un proceso difícil
 - ▣ Momentos, contornos, transformaciones, etc.

Características discriminantes

- Características discriminantes → patrón
- Determinar grado de pertenencia del patrón
- Definir funciones discriminantes
 - ▣ Asignar a un patrón su grado de semejanza respecto a cada clase




Funcionamiento de un clasificador

Esquema general

Ejemplo

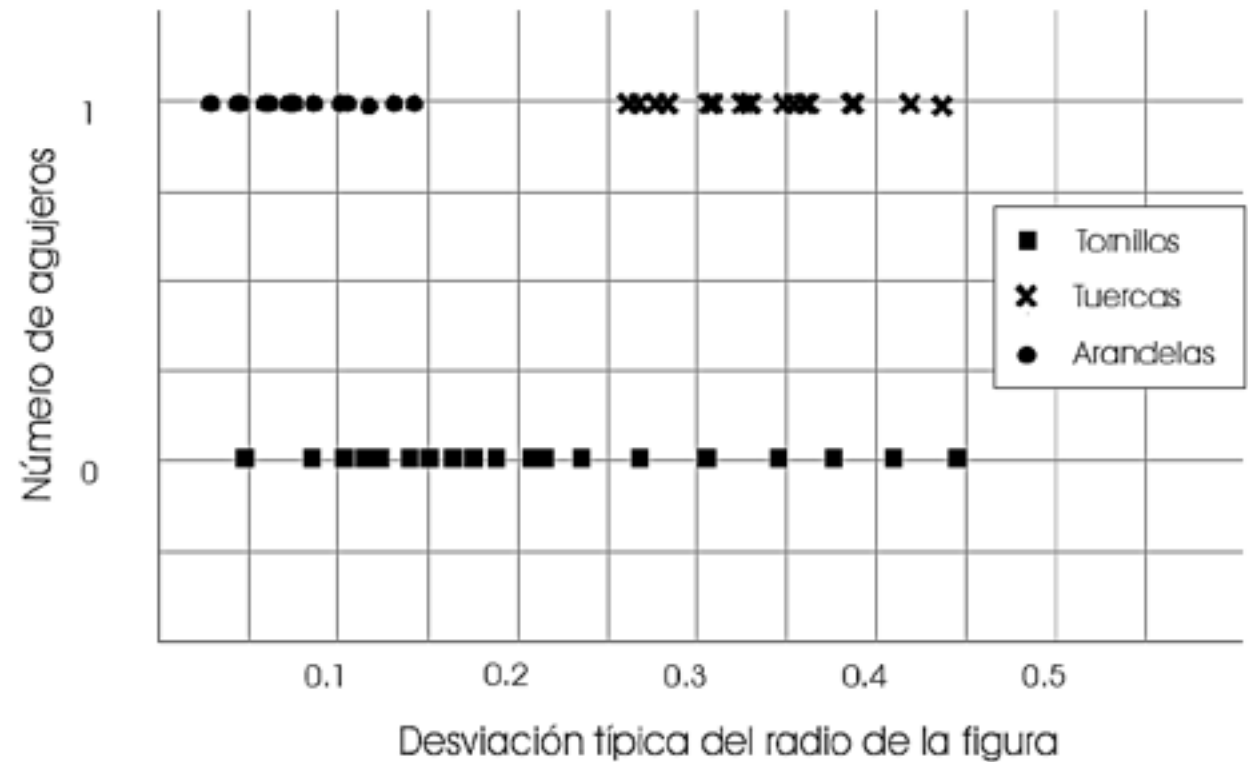
- Suponer una cinta donde circulan tornillos, arandelas y tuercas. Desarrollar un sistema que cuente cuántas unidades de cada tipo hay en cada momento en un intervalo de la cinta



Muestra de las diferentes piezas entre las que se desea distinguir, obtenidas con una cámara e iluminación a contraluz.

Ejemplo

- Segmentación
- Características para el reconocimiento
 - ▣ Número de agujeros
 - ▣ Desviación típica de las distancias del perímetro al centro del objeto
- Representación donde los patrones aparecen separados



A horizontal bar at the top of the slide, divided into a red section on the left and a blue section on the right.

Reconocimiento


Basado en métodos teóricos de decisión

Métodos teóricos de decisión

- Análisis en función discriminante
- Vector que dará una respuesta identificable con una clase de patrones y otra diferente en otra clase de patrones

Métodos teóricos de decisión

- Superficie de decisión lineal
- 2 características apropiadas representadas como puntos
- Superficie de decisión
 - ▣ Identificada y definida
 - ▣ Separar grupos
- Problema simple con 2 tipos de objetos



Métodos teóricos de decisión

- ▣ Enfoque simple

 - ▣ Función lineal

- ▣ Se define:

$$d(X) = X_1 - mX_2 - c$$

 - ▣ X_1 y X_2 : características medidas

 - ▣ m : pendiente de la línea


 - ▣ c : intersección del eje X_1

Clasificador de distancia mínima

- Puntos que caen en la línea:

$$d(X) = 0$$


- Punto sobre la superficie de decisión satisfacer $d(X) > 0$
- Punto bajo esta superficie satisfacer $d(X) < 0$
- Paso clave: Identificar y definir la superficie de decisión
 - ▣ Puede dibujarse un bisector perpendicular a la línea que une los valores de las medidas de los dos grupos de vectores



Ejemplo de muestras de Iris versicolor/Iris setosa

Clasificador de distancia mínima

- Problema de 3 clases
- 3 superficies de decisión lineal
- Cada clase representada por un grupo de medidas





Clasificador de distancia mínima

- Superficie de decisión distingue pares de grupos
- Algoritmo simple para deducir la clasificación correcta de cada vector característica desconocido

Clasificador de distancia mínima

- Dificultad de superficies de decisión:
 - ▣ Función apropiada
 - ▣ Superficie de decisión no lineal





Ejemplo de separación lineal entre clases

Clasificador de distancia mínima

- Tres vectores de características \rightarrow 3D
- # de características incrementa
 - ▣ Problema: ecuación de hiperplano
- Variaciones:
 - ▣ Fronteras de clasificación más complejas
 - ▣ Categorías no representadas adecuadamente por su media

Vecino más cercano

- Identificar un objeto por el grado de similitud con otros objetos
- Calcular distancia entre el objeto desconocido y los objetos vecinos dentro de cada grupo
- Distancias más pequeñas producen clases muestra para el objeto desconocido
- La clasificación final: tabular las decisiones muestra
- Elegir la clase con el mayor número de contribuciones

Algoritmos de agrupamiento

- No supervisados
- Requieren el vector de características de los objetos a reconocer
- Modos de operación:
 - ▣ Entrenamiento: Vectores de características de los objetos (conjunto de entrenamiento)
 - ▣ Clasificación: Asigna un vector de entrada a una clase

Algoritmos de agrupamiento

- Se pueden dividir en 2 grupos:
 - ▣ No requieren conocer el número de clases a priori
 - Algoritmo de distancias encadenadas
 - Algoritmo max-min
 - ▣ Sí requieren conocer el número de clases a priori
 - Algoritmo k-medias
 - Algoritmo de Bayes

Clasificadores estadísticos

- Enfoque probabilístico para el reconocimiento
- Consideraciones de probabilidad
 - ▣ Aleatoriedad bajo las cuales son generadas las clases
- Posible derivar un enfoque de clasificación óptimo
 - ▣ Probabilidad más baja de errores de clasificación

Clasificadores estadísticos

- No se consideraba la probabilidad de un vector de características
- P. ej.
 - ▣ Un problema de 2 clases donde el diseñador sabe *a priori* que hay un 99% de probabilidad de que un vector A esté presente, pero sólo un 1% de probabilidad de que el vector B esté presente
 - ▣ Si cada objeto desconocido se asume de tipo A habrá un 99% de promedio de éxito
- La probabilidad de ocurrencia de un objeto es importante

Referencias

- R. C. González & R. E. Woods, *Digital Image Processing*, 3^a ed., Prentice Hall, 2008
- R. Jain, R. Kasturi, B. G. Schunck, *Machine Vision*, McGraw Hill, 1995



Redes Neuronales

Redes Neuronales

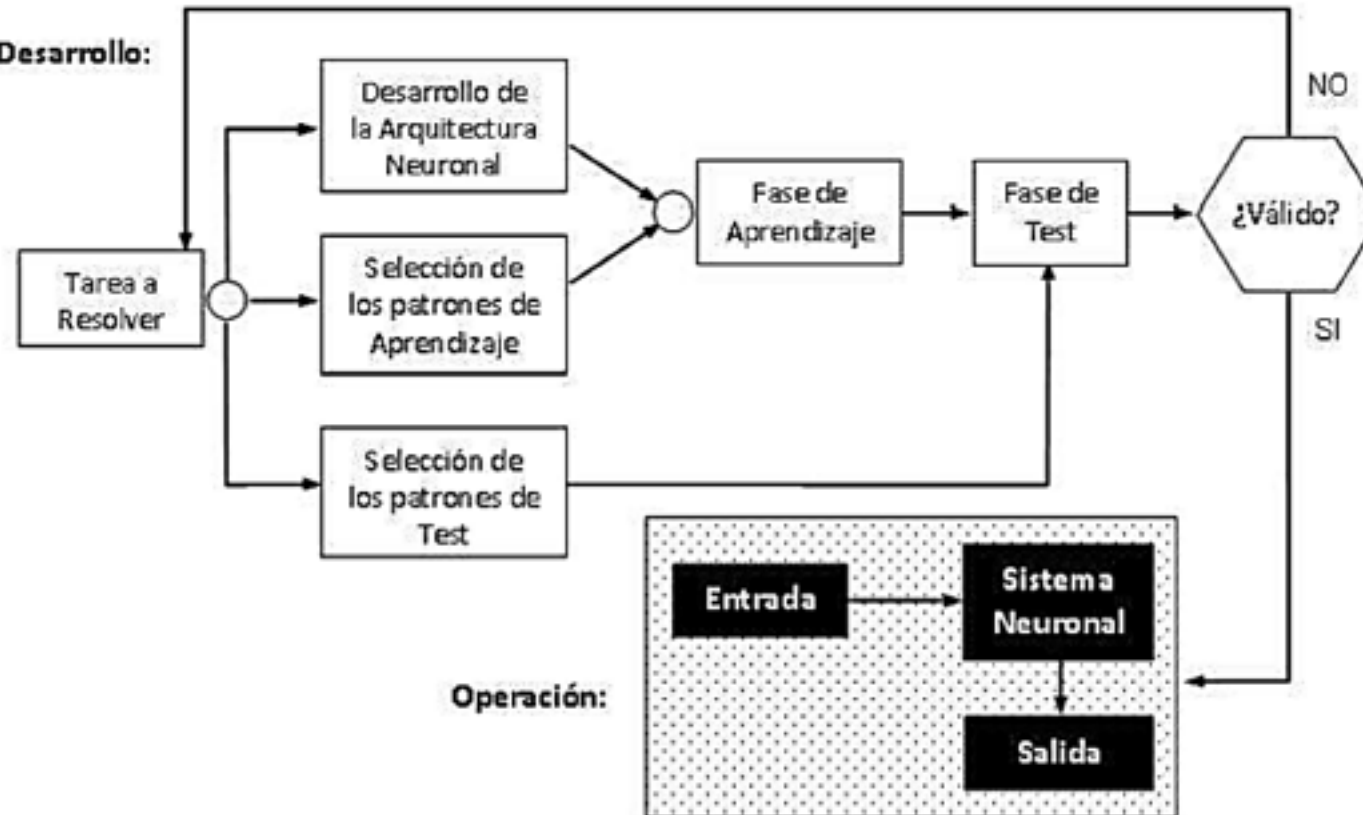
- Implementan un enfoque de clasificación
- Habilidad para particionar el espacio de características utilizando límites no lineales para las clases
 - ▣ Se obtienen al entrenar la red
- Durante el entrenamiento muchas instancias de objetos a ser reconocidos son mostrados

Redes Neuronales

- La red puede aprender los límites de clasificación en su espacio de características
 - ▣ Depende del conjunto de entrenamiento
- Durante la fase de reconocimiento, la red funciona como cualquier otro clasificador
- Ventajas: Habilidad para utilizar límites de clasificación no lineales; Habilidad de aprendizaje
- Limitaciones: Incapacidad de introducir hechos conocidos sobre el dominio de aplicación; Dificultad para depurar su rendimiento

Redes Neuronales

- Capacidad para extraer patrones y detectar tramas difíciles de apreciar por humanos o por otras técnicas computacionales



Redes Neuronales

Muestra de aprendizaje

- Conjunto de aprendizaje o de entrenamiento
- Conjunto de patrones similares a los que se quiere reconocer
- Necesarios para realizar el cálculo de las funciones discriminantes
- Se utilizan como modelos para crear la función discriminante
- La función discriminante clasificará correctamente los patrones del universo de trabajo

Redes Neuronales

Muestra de aprendizaje

- Conjunto de aprendizaje constituido por un subconjunto representativo del universo de trabajo
- En caso de muestra abundante se crea otro conjunto con ella
 - ▣ Conjunto de prueba: para probar los resultados de las funciones discriminantes

Recomendaciones:

- 60% de la muestra para el conjunto de aprendizaje
- 30% para el conjunto de prueba
- 10% para el conjunto de validación

Redes Neuronales

Criterios para la selección de características

- Buscar el conjunto mínimo de características que permitan determinar la pertenencia a clases
 - ▣ Una mala elección puede hacer que el sistema sea innecesariamente lento y costoso
- Propiedades que deben poseer las características elegidas:
 - ▣ Economía
 - ▣ Velocidad
 - ▣ Fiabilidad
 - ▣ Capacidad discriminante
 - ▣ Independencia respecto a otras características

Redes Neuronales

Propiedades que deben poseer las características elegidas:

- Economía
 - ▣ Mecanismo preciso para el cálculo de las características discriminantes con coste computacional razonable
- Velocidad
 - ▣ Tiempo de cálculo viable
- Fiabilidad
 - ▣ Objetos de la misma clase deben tener vectores de características con valores numéricos similares
 - ▣ Poca dispersión entre vectores

Redes Neuronales

Propiedades que deben poseer las características elegidas:

- Capacidad discriminante
 - ▣ Asegura que los patrones de clases distintas tienen valores numéricos claramente diferenciados

- Independencia respecto a otras características
 - ▣ Las características no deben estar correlacionadas entre ellas
 - ▣ Si alguna depende del resto no aporta información y puede eliminarse

Métodos estructurales



- Las técnicas anteriores tienen un enfoque cuantitativo respecto a los patrones
- Ignoran las relaciones estructurales inherentes en una forma de patrón
- Los métodos estructurales realizan el reconocimiento de patrones al capitalizar este tipo de relaciones